

SODIX API v3 Integrationsbefunde

Beobachtungen aus einem vollständigen Abzug des Metadatenbestands über `api3.sodix.de/graphql` und der anschließenden Abbildung auf das Allgemeine Metadatenprofil für Bildungsressourcen (AMB). Alle Zahlen sind gemessen, nicht geschätzt; jeder Befund nennt seine Belege.

STAND 25.08.2026	UMGEBUNG api3.sodix.de	ABGEZOGEN 203.810	LAUT TOTALCOUNT 215.868
NACH AMB 35.020	BEFUNDE 14		

ZUSAMMENFASSUNG

Worum es geht

Wir haben den kompletten Metadatenbestand über die API v3 abgezogen, um ihn als AMB-Metadaten weiterzuverarbeiten. Die Schnittstelle hat das insgesamt gut getragen — die Datenqualität ist dort, wo Felder belegt sind, hoch: von 35.020 abgebildeten Datensätzen war **kein einziger** unabbildbar.

Drei Dinge kosten allerdings unnötig Zeit oder Daten und lassen sich vermutlich mit begrenztem Aufwand beheben: eine Gruppe serverseitig unlesbarer Datensätze, ein defektes Zählfeld, und ein Feld (`source.publishers`), das pro Datensatz nachgeladen wird und Abfragen um den Faktor 11 verlangsamt.

Die restlichen Punkte sind Vokabular- und Dokumentationsdetails. Sie sind einzeln klein, führen bei einer Erstintegration aber zuverlässig in die Irre.

Alle Befunde, nach Auswirkung geordnet

GEWICHT	BEFUND	BETRIFFT
DATEN	Einzelne Datensätze sind serverseitig unlesbar und reißen die ganze Seite mit	≈ 2.900
DEFEKT	<code>Source.metadata.totalCount</code> läuft 49 s und endet im Fehler	alle Quellen
LEISTUNG	<code>source.publishers</code> wird je Datensatz aufgelöst (N+1)	Faktor 11
LEISTUNG	<code>pageSize: 1000</code> endet im <code>504 Gateway Time-out</code>	ab ≈ 500

GEWICHT	BEFUND	BETRIFFT
SEMANTIK	<code>rights.downloadRight</code> sagt nichts über die Verfügbarkeit eines Links	28.602
HYGIENE	Steuerzeichen in Beschreibungstexten brechen nachgelagerte Verarbeitung	2
VOKABULAR	Label-Sprachen sind je Vokabular verschieden, <code>lands</code> in sich gemischt	14 Listen
VOKABULAR	Sechs Werte im Sprachvokabular sind keine Sprachen	6
VOKABULAR	Drei Tippfehler in den Sprach-Enums	3
INTEROP	Vokabular-IDs sind interne Zahlenschlüssel, keine URIs	3 Listen
DOKU	Paginierung ist 0-basiert — nicht dokumentiert	—
DOKU	Playout-Doku nennt <code>metadata{identifier}</code> , das es in v3 nicht gibt	—
DOKU	<code>paidMedia.mediaLink</code> braucht eine undokumentierte Berechtigung	—
HINWEIS	Introspection wird ab einer gewissen Breite als „bad faith“ abgelehnt	—

DATENINTEGRITÄT

Befunde mit Datenverlust

Einzelne Datensätze sind serverseitig unlesbar

DATEN

Betroffene Datensätze beantworten *jede* Abfrage mit derselben Fehlermeldung — auch die Abfrage eines einzigen Feldes, und auch über `metadata.bySodixId` statt `search`. Von außen ist nichts zu retten.

```
// pageSize 100, Seite 139 → Fehler
// dieselbe Spanne in 10er-Schritten → 9 von 10 Teilabfragen liefern Daten
// pageSize 1, Offset 13994 → Fehler; Nachbarn 13993 und 13995 sind in Ordnung

{ metadata { bySodixId(sodixId: "SODIX-0001012370") { id } } }

"Exception while fetching data (/metadata/search) : null"
```

Weil ein defekter Datensatz die gesamte Seite mitnimmt, kostet er bei `pageSize: 100` seine 99 gesunden Nachbarn. Im ersten Vollabzug waren so **174 von 2.159 Seiten** betroffen — bis zu 17.400 Datensätze für einige hundert defekte.

UMGEHUNG Nicht ladbare Seiten aufteilen (100 → 10 → 1) und die gesunden Nachbarn einzeln holen. Das rettet 99 von 100 Datensätzen, kostet aber viele Zusatzabfragen.

BITTE PRÜFEN Ob diese Datensätze im Speicher reparabel oder wenigstens als „nicht auslieferbar“ markierbar sind, sodass sie eine Seite nicht mehr sprengen.

VORBEHALT Die Zahl ≈ 2.900 ist ein Zwischenstand; der Abzug lief bei Erstellung dieses Berichts noch. Die Größenordnung steht, die exakte Zahl noch nicht.

Source.metadata.totalCount ist unbrauchbar

DEFEKT

Das Feld verspricht die Anzahl der Datensätze je Quelle. Es braucht rund 49 Sekunden für 100 Quellen und endet dann im Fehler — reproduzierbar.

```
{ source { search(pageInput: { page: 3, pageSize: 100 }) {  
  data { id name metadata { totalCount } } } } }  
  
// 48,9 s, dann:  
"Exception while fetching data (/source/search/data[0]/metadata) : null"  
  
// ohne das Feld: 4,5 s für dieselben 100 Quellen
```

Das gleichnamige Feld an `MediaCollection` funktioniert dagegen einwandfrei (60 Sammlungen in 0,4 s) — das Problem ist also spezifisch für `Source`.

UMGEHUNG Feld weglassen und die Datensätze je Quelle offline über `source.id` auszählen.

WIRKUNG Das Weglassen brachte den Quellen-Abzug von 17 s pro Seite auf 3 s für alle 1.985 Quellen.

rights.downloadRight sagt nichts über einen Link

SEMANTIK

Naheliegend wäre, `downloadRight` als „Datei ist abrufbar“ zu lesen. Das führt in beide Richtungen in die Irre:

KONSTELLATION	DATENSÄTZE
PAID · <code>downloadRight: true</code> · keine <code>media.url</code>	8.200
NOT_PAID · <code>downloadRight: false</code> · <code>media.url</code> vorhanden	20.402

Der eigentliche Zusammenhang ist `paymentType`: Von 47.790 PAID-Datensätzen tragen **47.767 überhaupt keine Medien-URL** — weder `media.url` noch `media.downloadUrl`. Das ist plausibel, da Kaufmedien-Links über `paidMedia.mediaLink` rollen-, regions- und schulabhängig erzeugt werden; ein statischer Link im Datensatz wäre gar nicht möglich.

Die 23 Ausnahmen mit URL stammen aus nur zwei Quellen: „DaBi Schulfernsehen“ (21) und „test source (should be disabled)“ (2) — Letztere ist dem Namen nach nicht für die Auslieferung gedacht.

BITTE PRÜFEN Ob `downloadRight` so gemeint ist (Recht ≠ Verfügbarkeit). Wenn ja, wäre ein Satz in der Doku hilfreich; die Feldbezeichnung legt die andere Lesart nahe.

Steuerzeichen in Beschreibungstexten

HYGIENE

Zwei Datensätze enthalten in `general.description` C0-Steuerzeichen (`U+000B` vertikaler Tabulator, `U+0002`) — typische Reste aus Copy-und-Paste. Inhaltlich tragen sie nichts, brechen aber nachgelagerte Verarbeitung.

```
SODIX-0001034837    U+000B in general.description
SODIX-0001155910    U+000B, U+0002
```

Konkret bei uns: Für diese Zeichen gibt es in der Nostr-Serialisierung (NIP-01) keine Escape-Regel, weshalb Client und Server auf verschiedene Prüfsummen kommen und der Datensatz abgewiesen wird. Andere Abnehmer werden über kurz oder lang ähnliche Effekte sehen — XML- und CSV-Exporte reagieren auf C0-Zeichen ähnlich unfreundlich.

UMGEHUNG Wir filtern die betroffenen Zeichen beim Einlesen heraus.

BITTE PRÜFEN Ob sich eine Bereinigung bei der Erfassung oder beim Import einbauen lässt. Zwei Datensätze sind unkritisch — die Frage ist, ob nachrückende Importe weitere mitbringen.

LEISTUNG

Was den Abzug ausbremst

`source.publishers` wird je Datensatz nachgeladen

N+1

Wird `source.publishers` in einer Metadaten-Abfrage mitselektiert, steigt die Antwortzeit um etwa den Faktor 11 — das Muster eines N+1-Zugriffs.

100 Datensätze, alle Felder	0,8 s
100 Datensätze, alle Felder + <code>source.publishers</code>	9,0 s
1000 Datensätze mit <code>source.publishers</code>	504 Gateway Time-out (nach 60 s)

UMGEHUNG Herausgeber getrennt abziehen (972 Datensätze) und über `source.id` verknüpfen.

BITTE PRÜFEN Ob die Auflösung sich je Anfrage bündeln lässt (Dataloader-Muster). Die Herausgeber-Menge ist klein und ändert sich selten — sie wäre gut cachebar.

Große `pageSize` -Werte laufen ins Zeitlimit

LEISTUNG

Die Dokumentation nennt 1000 als Maximum. Praktisch erreichbar war das mit vollem Feldsatz nicht:

<code>pageSize</code>	50	4,6 s
<code>pageSize</code>	100	9,0 s
<code>pageSize</code>	200	20,5 s
<code>pageSize</code>	500	54,6 s
<code>pageSize</code>	1000	504 Gateway Time-out

Mit reduziertem Feldsatz sind 100–200 problemlos. Positiv: tiefe Offsets sind unproblematisch — Offset 140.000 liefert zuverlässig Daten, es gibt also kein Fenster-Limit wie bei manchen Suchindizes.

BITTE PRÜFEN Ob das Zeitlimit angehoben werden kann, oder ob die Doku einen realistischen Wert nennen sollte.

VOKABULARE

Details, die bei der Abbildung stolpern lassen

Label-Sprachen sind je Vokabular verschieden

VOKABULAR

Das `name` -Feld der Vokabulare ist nicht durchgängig in einer Sprache. Wer es pauschal als deutsch oder englisch behandelt, erzeugt falsche Sprachangaben.

VOKABULAR	SPRACHE	BEISPIEL
<code>lrts</code> , <code>educationLevels</code> , <code>schoolTypes</code> , <code>costs</code>	englisch	„Secondary school I“
<code>subjects</code> , <code>competences</code> , <code>occupationAreas</code>	deutsch	„Chemie“
<code>lands</code>	gemischt	„Baden-Württemberg“ neben „Bavaria“
<code>learningFields</code>	numerisch	„1“, „2“, „3“

BITTE PRÜFEN Ob die Namen langfristig sprachmarkiert ausgeliefert werden können, etwa `name(language:)` wie bei `vocationalSchoolCompetencies` — dort gibt es das Argument schon.

Sechs Werte im Sprachvokabular sind keine Sprachen

VOKABULAR

`general.languages` mischt Sprachen mit Fassungs- und Barrierefreiheitsmerkmalen. Für eine Abbildung auf BCP-47 müssen diese sechs Werte aussortiert werden:

```
WITHOUT_LANGUAGE
AUDIO_DESCRIPTION
ORIGINAL_VERSION_WITH_SUBTITLES
PLAIN_LANGUAGE
SIMPLE_LANGUAGE
SUBTITLES_FOR_THE_HEARING_IMPAIRED
```

Fachlich sind das eher Barrierefreiheitsmerkmale (vgl. `accessibilityFeature` in `schema.org`) als Sprachen. Ein eigenes Feld wäre sauberer und für Barrierefreiheitsfilter direkt nutzbar.

Drei Tippfehler in den Sprach-Enums

VOKABULAR

```
ALBANIAN → gemeint: Albanian (sq)
CROATIAN → gemeint: Croatian (hr)
IRIS      → gemeint: Irish    (ga)
```

Enum-Werte zu ändern ist ein Bruch für bestehende Clients — vielleicht eher etwas für einen künftigen Versionssprung als für einen Patch. Wir haben sie clientseitig auf die korrekten Codes abgebildet.

Vokabular-IDs sind interne Zahlenschlüssel

INTEROP

Kompetenzen, Fächer und Berufsfelder tragen IDs wie `40004020201`, `100` oder `11`. AMB und LRMI erwarten an den entsprechenden Stellen URIs, weshalb sich diese Werte nicht direkt in die Kernfelder übernehmen lassen — Kompetenzen etwa können nicht nach `teaches`, weil dort eine URI verlangt wird.

UMGEHUNG Die SODIX-Oberfächer sind über ihre deutschen Labels auf die KIM-Schulfächer abbildbar; wir haben 24 der 38 zuordnen können. Der Rest wird als quellenspezifische Erweiterung mitgeführt.

BITTE PRÜFEN Ob den Vokabularen zusätzlich eine URI beigegeben werden kann — idealerweise direkt die KIM-URIs (`w3id.org/kim/schulfaecher`, `hcrt`, `iscid-1997`). Das würde jede AMB-, OERSI- und LOM-Integration deutlich vereinfachen.

Kleine Korrekturen mit großer Wirkung

Die Paginierung ist 0-basiert

[DOKU](#)

`page: 0` ist die erste Seite. Die Dokumentation beschreibt `page` als „Nummer der Gruppe“, was 1-basiert nahelegt. Wer so zählt, verliert die ersten `pageSize` Datensätze — ohne Fehlermeldung.

```
page: 0, pageSize: 2 → BY-00021687, BY-00021700
page: 1, pageSize: 2 → BY-00021701, BY-00021702 // schließt direkt an
```

BITTE PRÜFEN Ein Satz in der Doku („0-basiert“) genügt. Das ist der Befund mit dem besten Verhältnis von Aufwand zu Nutzen.

Playout-Doku nennt ein Feld, das es in v3 nicht gibt

[DOKU](#)

Der Playout-Abschnitt verweist auf `metadata{identifizier}` als Eingabe für `getPlayoutWindow`. Im v3-Schema existiert `identifizier` nicht; das Feld heißt `sodixId`.

`paidMedia.mediaLink` braucht eine undokumentierte Berechtigung

[DOKU](#)

Der Aufruf liefert mit einem `ROLE_API`-Konto für alle Varianten `null`, was wegen der Non-Null-Deklaration die gesamte Abfrage in einen Fehler kippt.

```
{ paidMedia { mediaLink(input: { sodixId: "BWS-02958010", role: TEACHER })
  { size links { href linkType } } } }
```

```
"The field at path '/paidMedia/mediaLink' was declared as a non null type,
but the code involved in retrieving data has wrongly returned a null value."
```

Getestet mit `TEACHER` und `LEARNER`, jeweils mit und ohne `region`. Vermutlich fehlt dem Konto die ARIX-Berechtigung — das ist nachvollziehbar, aber der Fehlertext führt in eine ganz andere Richtung.

BITTE PRÜFEN Welche Berechtigung ein Konto für Kaufmedien-Links braucht, und ob der Fehlerfall als `null` mit Begründung statt als Schema-Verletzung zurückkommen kann.

Introspection wird ab einer gewissen Breite abgelehnt

HINWEIS

Mehrere `inputFields`-Blöcke in einer Abfrage werden abgewiesen:

```
"This request is not asking for introspection in good faith
- __Type.inputFields is present too often!"      (BadFaithIntrospection)
```

Als Schutzmaßnahme sinnvoll — hier nur als Hinweis für andere Integrationen: Input-Typen müssen einzeln abgefragt werden.

POSITIV

Was gut funktioniert hat

- **Die Datenqualität trägt.** Von 35.020 auf AMB abgebildeten Datensätzen war keiner unabbildbar — Pflichtfelder wie Titel sind durchgängig belegt.
- **Einheitliche Formate.** `media.duration` liegt im gesamten Bestand in genau einem Format vor (134.301 geprüfte Werte), `media.dataType` ist bereits ein IANA-Medientyp, `media.thumbnail` ist zu 100 % belegt.
- **Tiefe Paginierung ist unproblematisch.** Kein Fenster-Limit; Offset 140.000 liefert zuverlässig.
- **Stabile Authentifizierung.** Der Token gilt rund 8 Stunden (`expiresIn: 28799`) und verhält sich über lange Läufe berechenbar.
- **Delta-Abfragen sind vorhanden.** `time.anyUpdate` und `time.updatedInSodix` erlauben echte inkrementelle Abgleiche — das ist für den laufenden Betrieb wichtiger als jede Durchsatzoptimierung.
- **Nebenbestände sind schlank.** 1.985 Quellen, 972 Herausgeber, 60 Sammlungen und 21 Vokabularlisten sind in wenigen Sekunden vollständig abrufbar.

Methode. Vollabzug über `metadata.search` mit `orderBy: createdAt ASC`, `pageSize` 100, vier bis sechs parallelen Anfragen, gegen `api3.sodix.de`. Zeitmessungen sind Einzelmessungen aus derselben Sitzung und als Größenordnung zu lesen, nicht als Benchmark. Alle Datensatzzahlen stammen aus dem abgezogenen Bestand (203.810 Datensätze) und lassen sich über `totalCount` gegenprüfen.

Die Zahl der unlesbaren Datensätze ist ein Zwischenstand — der Abzug lief bei Erstellung dieses Berichts noch. Wir reichen die endgültige Liste der betroffenen Identifier gern nach; sie wird beim Abzug ohnehin protokolliert.